

AfriShop Lakehouse : rapport final, vidéo et liste de vérification

Oct 2, 2026 · @Cheikh Sall

Résumé exécutif

AfriShop dispose d'une plateforme de données reproductible, de la source brute jusqu'aux tableaux de bord, qui traite 50 000 commandes, 81 180 clients et 12 000 produits dans 4 pays (Sénégal, Nigeria, Ghana, Côte d'Ivoire). Le pipeline est idempotent : un rejeu ne change aucun volume. Il est versionné (v1.0.0), testé (23 tests Python, 65 tests dbt, couverture 63,64 %) et documenté.

Trois messages pour la direction :

- **Le revenu est concentré** : les segments Champions et Loyaux font 58 % de la valeur client avec 39 % des clients actifs, et 4 802 produits de classe A (51 % des produits vendus) portent 80 % du chiffre d'affaires.
- **Le suivi des paiements est le premier chantier** : 27,7 % des lignes de vente n'ont aucun paiement rattaché, et 6 848 commandes livrées n'ont pas de paiement enregistré.
- **Les clients à risque valent presque autant que les Champions** : 6 428 clients « À risque » représentent 28,8 % de la valeur, soit la plus grande poche de revenu récupérable.

Les montants sont en devise locale (XOF, NGN, GHS) et ne sont jamais additionnés entre pays, faute de taux de change fiables.

Contexte, données sources et qualité

Les six sources (clients, produits, commandes, lignes, paiements, livraisons) arrivent en Parquet et passent par trois contrôles : règles de nettoyage Spark, quarantaine des lignes invalides et les suites Great Expectations avant publication.


Indicateur	Valeur	Lecture
Commandes en couche curated	50 000	Volume stable après backfill
Clients (après fusion master_customer_id)	81 180	Doublons rapprochés par e-mail haché
Produits	12 000	9 471 ont au moins une vente

Indicateur	Valeur	Lecture
Lignes de vente (fact_order_line)	105 409	Jointures à la date de validité (SCD2)
Commandes mises en quarantaine	500	Motif unique : aucune ligne de commande
Commandes annulées	6 115 (12,2 %)	Hors chiffre d'affaires
Paielements partiels	321	Commandes payées en plusieurs fois
Commandes sans paiement	13 815	dont 6 848 déjà livrées

Les données personnelles (e-mail) sont hachées en SHA-256 salé avant la couche curated. Le sel (HASH_SALT) reste hors du dépôt Git.

Architecture et choix techniques

Les données traversent quatre couches, contrôlées et orchestrées



architecture lakehouse · 4 couches, 2 contrôles

Chaque couche a un rôle unique : raw conserve la donnée telle qu'elle arrive, curated la nettoie, PostgreSQL la sert, dbt la transforme en indicateurs.

- **Idempotence** : les écritures curated utilisent un MERGE Delta, donc un rejeu ou un backfill ne crée aucun doublon (volumes inchangés après test).
- **Historique** : Delta garde les versions (time travel), et dim_customer et dim_product suivent les changements en SCD2 avec jointure à la date de validité.

- **Confidentialité** : e-mails hachés avec un sel secret, jamais commité ; seul .env.example est dans Git.
- **Orchestration** : tâches Airflow dynamiques par source, 2 relances avec attente croissante, alertes en cas d'échec, métriques de chaque exécution dans ops.pipeline_runs.
- **Qualité** : Great Expectations bloque la publication ; 65 tests dbt vérifient le modèle ; ruff, black, mypy et sqlfluff gardent le code propre.

Résultats analytiques

L'activité vient surtout du mobile et des zones urbaines, 60 % des commandes sont livrées, et la valeur client se concentre sur deux segments.

Activité. Le Sénégal pèse 35 % des commandes, le Nigeria 30 %, le Ghana 20 % et la Côte d'Ivoire 15 %. L'application mobile fait 55,3 % des commandes, le web 24,6 % et le bot WhatsApp 12,1 %. Les zones urbaines représentent 60,4 % des commandes, les péri-urbaines 28 % et les rurales 11,6 %.

Chiffre d'affaires (commandes hors annulées et en attente, en devise locale) :

Devise	Pays	Commandes	Chiffre d'affaires
XOF	Sénégal, Côte d'Ivoire	21 149	2,52 milliards
NGN	Nigeria	12 754	1,51 milliard
GHS	Ghana	8 474	1,01 milliard

Segments RFM (30 056 clients ayant acheté) :

Segment	Clients	Part de la valeur
Champions	4 771	31,9 %
À risque	6 428	28,8 %
Loyaux	6 834	26,4 %
Perdus	5 275	5,4 %
Nouveaux ou prometteurs	4 090	4,4 %
À surveiller	2 658	3,1 %

Les parts de valeur additionnent des montants en devises différentes : elles servent à comparer des segments, pas à chiffrer un montant total.

Produits. La classe A compte 4 802 produits et 3,70 milliards de ventes (80 % du total), la classe B 2 355 produits, la classe C 2 314 produits et 0,23 milliard.

Retours. Le taux de retour est de 7,9 à 8,8 % selon le pays (le plus haut en Côte d'Ivoire) et de 8,0 à 8,6 % selon la catégorie (Sport en tête, Maison et Beauté en bas) : aucune catégorie ne ressort nettement.

Livraisons. Sur 29 287 livraisons terminées, 1 437 sont en retard (4,9 %).

Recommandations pour la direction

Quatre actions, classées par ordre de priorité ; chacune s'appuie sur un chiffre du pipeline et se suit par un indicateur.

Priorité	Action	Constat chiffré	Indicateur de suivi
1	Fiabiliser l'enregistrement des paiements (surtout paiement à la livraison et mobile money)	13 815 commandes sans paiement dont 6 848 livrées ; 27,7 % des lignes de vente sans paiement	Part de commandes livrées sans paiement
2	Lancer une campagne de réactivation ciblée sur le segment À risque	6 428 clients, 28,8 % de la valeur	Taux de retour à l'achat sous 90 jours
3	Protéger la disponibilité des produits de classe A	4 802 produits font 80 % des ventes	Rupture de stock sur la classe A
4	Traiter les retours et retards par pays plutôt que par catégorie	Retours 7,9 à 8,8 % par pays, 8,0 à 8,6 % par catégorie ; 4,9 % de livraisons en retard	Taux de retour et de retard par pays

Deux actions de fond accompagnent ces quatre priorités : fixer des taux de change officiels pour comparer les pays en une seule devise, et brancher Power BI sur le schéma analytics pour que la direction suive ces indicateurs sans passer par l'équipe data.

Biais, limites et usages interdits

Les résultats sont fiables pour comparer des segments et des produits, mais pas pour chiffrer un total multi-pays ni pour décider du sort d'un client.

- **Devises non comparables** : XOF, NGN et GHS sont convertis avec un taux neutre de 1,0, donc aucun total multi-pays n'a de sens financier.
- **Sur-représentation urbaine** : 60,4 % des commandes viennent de zones urbaines, et les conclusions reflètent surtout ces clients.
- **Paiements manquants** : 27,7 % des lignes sans paiement peuvent venir d'un défaut de collecte (paiement à la livraison) autant que d'un vrai impayé.
- **Retours** : une seule fenêtre de 2 mois est recalculée en incrémental, donc les retours très tardifs sont hors fenêtre.
- **Usage interdit** : le score RFM ne doit jamais servir à exclure un client, à dégrader son service ou à fixer son prix ; il sert à prioriser des actions commerciales.

Le détail est dans docs/bias_and_limits.md du dépôt.

Script de la vidéo de démonstration

La vidéo dure environ 8 minutes en 8 scènes ; chaque scène montre une preuve concrète plutôt qu'un diaporama.

#	Durée	À l'écran	Ce que vous dites
1	0:45	Schéma d'architecture du README	« AfriShop vend dans 4 pays ; ses données étaient dispersées. Voici la plateforme qui les centralise. »
2	1:00	Dossiers raw et curated, tables Delta	« Les fichiers bruts sont conservés, puis nettoyés ; les e-mails sont hachés et les lignes invalides vont en quarantaine. »
3	1:15	Interface Airflow, vue Graph du DAG vert	« Un DAG exécute ingestion, nettoyage, contrôles qualité et dbt, avec relances et alertes. »
4	1:00	Terminal : <code>dbt build</code> , 65 tests réussis	« Le modèle en étoile est validé par 65 tests automatiques. »
5	1:00	Data Docs Great Expectations	« Chaque lot est contrôlé avant publication ; un échec bloque la suite. »
6	1:15	Script de livraison tardive, puis requête time travel	« Une donnée arrive en retard : le pipeline la gère sans doublon, et je peux relire l'ancienne version. »

#	Durée	À l'écran	Ce que vous dites
7	1:15	Tableau Power BI et schéma de lignée dbt	« Voici RFM, rotation des produits et taux de retour, avec les trois recommandations. »
8	0:30	Tag v1.0.0, README, runbook	« Tout est versionné, testé et documenté ; le runbook explique comment l'exploiter. »

Avant d'enregistrer, rejouez le backfill pour montrer que les volumes restent à 50 000 commandes, 81 180 clients et 12 000 produits.

Liste de vérification finale

Tout le socle technique est validé sur ta machine ; il reste les livrables de présentation à produire et un service optionnel non réalisé.

- ☒ Lakehouse raw, curated et analytics, avec Delta Lake et MERGE idempotent
- ☒ Backfill rejoué : 50 000 commandes, 81 180 clients, 12 000 produits inchangés
- ☒ Modèle en étoile PostgreSQL avec SCD2 sur clients et produits
- ☒ 65 tests dbt (objectif : au moins 35)
- ☒ Tests Python : 23 réussis, couverture 63,64 % (objectif : 60 %)
- ☒ Great Expectations avec Data Docs
- ☒ Airflow : relances, SLA, alertes, métriques dans ops.pipeline_runs
- ☒ Démo de livraison tardive et time travel Delta, avec script de remise à zéro
- ☒ Dictionnaire de données, runbook, documentation des biais
- ☒ README avec architecture, CHANGELOG et tag v1.0.0 poussé
- ☒ Captures du schéma de lignée dbt (fact_order_line, mart_customer_rfm) dans docs/images/
- ☒ Rapport final en PDF, construit à partir de ce document
- ☐ Tableau de bord Power BI branché sur le schéma analytics (hors rendu, à poursuivre ensuite)
- ☐ Vidéo de démonstration enregistrée selon le script (hors rendu, à poursuivre ensuite)
- ☐ Services spark-master et spark-worker (optionnel, non réalisé)